



Evaluación RAG

Desarrollo de aplicaciones con IA

Presenta:

Andrés Ricardo Cáceres Ortiz

Fundación Universitaria Konrad Lorenz

Facultad de Matemáticas e ingenierías

Programa de ingeniería en Sistemas

Bogotá, D.C. abril 2026

EVALUACIÓN DE PIPELINE RAG CON RAGAS

Taller

Objetivo

Medir el desempeño del pipeline RAG implementado usando la librería RAGAS y presentar los resultados con análisis crítico. El sistema recupera información de documentos PDF académicos propios para responder preguntas sin necesidad de reentrenar el modelo de lenguaje.

Preparación de la Evaluación

Parámetros del Pipeline

La siguiente tabla resume la configuración utilizada en el sistema RAG evaluado:

Parámetro	Valor
Documento(s)	reglamento_academico.pdf programas_asignaturas.pdf
Modelo de embeddings	gemini-embedding-001 (Google, 3072 dim)
chunk_size / overlap	500 caracteres / 50 caracteres
k (chunks recuperados)	5
LLM generador	gemini-2.5-flash (temperature = 0.1)
LLM juez (RAGAS)	gemini-2.5-flash

Descripción de los Documentos

Se utilizaron dos documentos PDF propios, generados específicamente para este taller:

- reglamento_academico.pdf — Contiene 6 secciones: becas, inasistencias, exámenes extraordinarios, apoyo a investigación, régimen disciplinario y recursos tecnológicos.
- programas_asignaturas.pdf — Contiene 8 programas de asignaturas de Ingeniería de Sistemas con créditos, semestre, objetivos, temas y competencias.

Casos de Prueba

Se diseñaron 8 preguntas, 2 de cada tipo, cubriendo los cuatro escenarios de evaluación requeridos:

Tipos de preguntas:

- Tipo A (Textual): La respuesta aparece literalmente en el documento. Mide recuperación exacta.
- Tipo B (Semántico): El vocabulario es diferente al del documento. Prueba la calidad de los embeddings.
- Tipo C (Multi-chunk): Requiere combinar información de varios fragmentos. Prueba la integración del contexto.

- Tipo D (Alucinación): El sistema no debería tener la respuesta. Detecta si el LLM inventa información.

#	Tipo	Pregunta	Respuesta esperada
1	A – Textual	¿Cuántos créditos tiene Pre-Cálculo?	3 créditos, Semestre 1.
2	A – Textual	¿Cuál es el promedio mínimo para examen extraordinario?	2.8 sobre 5.0.
3	B – Semántico	¿Qué ayuda económica recibe un alumno con notas sobresalientes?	Incentivo del 30% de la matrícula (promedio > 4.5).
4	B – Semántico	¿Qué pasa si un estudiante deja de estudiar sin avisar?	Sanción: pérdida de certificados por 2 semestres.
5	C – Multi-chunk	¿Qué materias hay en Semestre 1 y cuántos créditos suman?	Pre-Cálculo + Cálculo + Lógica + Comunicativas = 12 créditos.
6	C – Multi-chunk	¿Causas válidas para examen extraordinario y promedio mínimo?	Enfermedad, duelo 1.er grado, calamidad. Mínimo 2.8.
7	D – Alucinación	¿Cuál es el nombre del rector y cuándo fue elegido?	No encontré información sobre esto en el documento.
8	D – Alucinación	¿Cuánto cuesta la matrícula exacta en pesos para 2024-2?	No encontré información sobre esto en el documento.

Resultados de la Evaluación RAGAS

RAGAS evalúa el sistema usando un LLM juez (gemini-2.5-flash) que puntúa cada pregunta con tres métricas independientes entre 0 y 1:

- Faithfulness: proporción de hechos en la respuesta que provienen del contexto recuperado (detecta alucinaciones).
- Answer Relevancy: similitud semántica entre la respuesta generada y la pregunta (mide pertinencia).
- Context Precision: proporción de fragmentos recuperados que realmente eran útiles para responder (mide eficiencia del retriever).

#	Tipo	Pregunta (resumida)	Faithfulness	Answer Relevancy	Context Precision	Análisis
1	A	¿Créditos Pre-Cálculo?	1.00	0.97	1.00	Fragmento exacto recuperado.
2	A	¿Promedio examen ext.?	1.00	0.95	1.00	Dato numérico hallado.
3	B	¿Ayuda con buenas notas?	0.92	0.89	0.80	Embedding semántico exitoso.
4	B	¿Qué pasa si abandona?	0.88	0.91	0.75	Sinónimos mapeados bien.

5	C	¿Materias Semestre 1?	0.85	0.87	0.70	Varios chunks; contexto parcial.
6	C	¿Causas examen extra.?	0.90	0.88	0.75	Combinación lograda.
7	D	¿Nombre del rector?	1.00	0.60	0.20	No alucinó; admitió ignorancia.
8	D	¿Costo matrícula 2024?	1.00	0.62	0.15	Respuesta correcta: no sé.
		Promedio global	0.94	0.84	0.67	Sistema robusto con k=5.

Análisis Crítico

Faithfulness — 0.94 (Excelente)

El pipeline obtiene una fidelidad muy alta. El 94% de los hechos en las respuestas provienen del contexto recuperado. Destaca que las preguntas Tipo D (alucinación) obtuvieron faithfulness perfecta (1.00), ya que el sistema respondió correctamente admitiendo que no tenía la información. Esto indica que el prompt es suficientemente restrictivo para evitar que el LLM invente datos.

Answer Relevancy — 0.84 (Bueno)

Las preguntas Tipo D muestran relevancia menor (≈ 0.61), lo cual es esperable: cuando la respuesta es 'No encontré información', la similitud semántica con la pregunta es baja por diseño. Si se excluyen estas dos preguntas, la relevancia promedio sube a 0.91, lo que indica que el sistema responde apropiadamente las preguntas que sí puede responder.

Context Precision — 0.67 (Aceptable)

Esta es la métrica más débil y señala el principal punto de mejora. Con $k=5$, el retriever recupera fragmentos que no siempre son relevantes. En las preguntas Tipo D, la precision es muy baja (0.15–0.20) porque el documento no contiene la información, por lo que ningún fragmento es útil. Las preguntas Tipo C también muestran precision moderada (0.70–0.75) al requerir varios fragmentos distribuidos.

Recomendaciones de Mejora

- Reducir k a 3 para preguntas simples (Tipo A y B): mejoraría context_precision significativamente.
- Implementar reranking con un modelo cross-encoder para filtrar los fragmentos más relevantes antes de enviarlo al LLM.
- Aumentar chunk_overlap a 100 caracteres para reducir la pérdida de contexto en los bordes de los fragmentos (beneficiaría las preguntas Tipo C).
- Considerar un retriever híbrido (BM25 + semántico) para mejorar la recuperación de datos numéricos exactos.

Conclusión

El pipeline RAG implementado demuestra un desempeño robusto y confiable. La alta faithfulness garantiza que el sistema no alucina información. La buena answer_relevancy confirma que las

respuestas son pertinentes. El área de mejora es context_precision, directamente relacionada con la selección del valor de k y la estrategia de chunking. El sistema es adecuado para un escenario de asistente académico sobre documentos propios.